
Trabalho Final - Relatório

Parte II

Grupo Spotify

Disciplina: Banco de Dados

Nome: Dhemerson Sousa de Albuquerque	DRE: 123751184
Nome: Ricardo Augusto de Borba	DRE: 124012274
Nome: Mariana Kellen Araújo Moreira	DRE: 123753178
Nome: Pedro Salazar Pessoa Machado	DRE: 123270780
Nome: Emilly Tavares da Silva	DRE: 123750578

Introdução

=====

O trabalho tem como objetivo desenvolver o projeto conceitual de um banco de dados, baseado em informações musicais obtidas em datasets do Spotify. O objetivo do tema escolhido foi a organização e consulta de dados relacionados a músicas, artistas, álbuns e gêneros musicais.

Para o desenvolvimento do projeto, foi utilizado um conjunto de dados contendo informações de faixas musicais catalogadas na plataforma Spotify, incluindo dados básicos relacionados às próprias músicas, e demais características relacionadas aos seus respectivos artistas e álbuns. A partir desses dados, será desenvolvida uma aplicação Web simples voltada para buscas e visualização de informações musicais em uma interface gráfica.

O projeto busca representar de forma adequada as relações existentes entre músicas, artistas, álbuns, gêneros musicais, características sonoras das faixas e métricas de popularidade. Começados a partir de um modelo entidade-relacionamento, a partir das informações reais e estrutura presentes no dataset selecionado.

Datasets

=====

O conjunto de dados utilizado no projeto foi o Spotify Tracks Dataset, obtido através da plataforma Kaggle. O dataset foi disponibilizado no formato CSV, e contém uma grande quantidade de músicas catalogadas juntamente com demais informações listadas anteriormente.

O dataset foi escolhido por possuir informações suficientes para a construção de um modelo conceitual coerente, bem como para testar o bom funcionamento do banco de dados, posteriormente.

[Spotify Tracks Dataset](#)

Os campos analisados no dataset foram:

track_id
artists
album_name
track_name
popularity
duration_ms
explicit
danceability
energy
key
loudness
mode
speechiness
acousticness
instrumentalness
liveness
valence
tempo
time_signature
track_genre

Após a análise dos dados, foram identificadas quatro entidades principais para a modelagem do banco de dados:

- Música
- Artista
- Álbum
- Gênero

Os tipos presumidos dos dados presentes no dataset incluem:

Campo	Tipo Presumido	Valores Típicos
<code>track_id</code>	String	Identificadores únicos de músicas
<code>artists</code>	String	Nome de artistas ou múltiplos artistas separados por ";"
<code>album_name</code>	String	Nome de álbuns musicais
<code>track_name</code>	String	Nome das músicas
<code>popularity</code>	Integer	Valores entre 0 e 100
<code>duration_ms</code>	Integer	Duração da música em milissegundos
<code>track_genre</code>	String	Categorias de gêneros musicais

Demais campos no dataset representam características técnicas e métricas de áudio das músicas disponibilizadas pelo Spotify.

Projeto do Banco de Dados

===== (a) Modelo Conceitual

O modelo conceitual desenvolvido foi construído a partir das informações reais presentes no dataset selecionado. Durante a modelagem foram identificadas quatro entidades principais: Musica, Artista, Album e Genero.

A entidade Musica detém os principais atributos relacionados à cada faixa musical, como identificador, nome, popularidade e tempo da música. As entidades Artista, Album e Genero foram definidas para representar as informações associadas a diferentes agrupamentos de músicas presentes no dataset.

Os relacionamentos foram definidos com base nas associações observadas nos dados. O relacionamento entre Artista e Musica possui cardinalidade muitos-para-muitos, n:n, uma vez que uma música pode possuir múltiplos artistas e um artista pode produzir várias músicas. Além disso, esse relacionamento possui o atributo *tipo_participacao*, que o Spotify utiliza para distinguir entre participações principais ou colaborações secundárias por artistas.


No modelo conceitual desenvolvido, foi definido um relacionamento entre Musica e Genero. Embora no contexto real uma música possa estar associada a múltiplos gêneros musicais, ao seguirmos o Spotify Tracks Dataset, cada faixa possui apenas um único gênero registrado no campo *track_genre*. Dessa forma, a cardinalidade adotada no modelo foi de 1:1 para Música em relação

a Gênero. Na direção oposta da relação, um gênero pode estar associado a várias músicas, então teremos uma cardinalidade 1:n.

Também foram modelados os relacionamentos entre Album e Musica, e entre Gênero e Musica, representando, respectivamente, o álbum ao qual cada música pertence, e sua classificação em categorias arbitrárias pelo Spotify.

O diagrama entidade-relacionamento correspondente ao modelo conceitual, de acordo com o que foi escrito, segue abaixo:

Modelo E.R - Imagem



(b) Modelo Lógico

O modelo lógico foi desenvolvido a partir da conversão do modelo conceitual elaborado anteriormente, aplicando as regras de transformação entre entidades, relacionamentos e tabelas relacionais. Nessa etapa, as entidades identificadas no modelo conceitual foram convertidas em relações contendo seus respectivos atributos, chaves primárias e chaves estrangeiras.


As entidades Artista, Album, Gênero e Musica foram convertidas diretamente em tabelas independentes, preservando os atributos definidos durante a etapa conceitual. A tabela Musica passou a armazenar também chaves estrangeiras relacionadas às tabelas Album e Gênero, representando os relacionamentos 1:1 identificados anteriormente.

O relacionamento muitos-para-muitos entre Artista e Musica foi convertido para uma tabela intermediária denominada Participacao. Essa conversão foi necessária pois relacionamentos N:N não podem ser representados diretamente em modelos relacionais. Dessa forma, a tabela Participacao passou a armazenar as chaves estrangeiras das tabelas Artista e Musica, além do atributo tipo_participacao, utilizado para distinguir diferentes formas de colaboração entre artistas.

As cardinalidades observadas no modelo conceitual foram preservadas durante a conversão para o modelo lógico, garantindo que as restrições existentes nos dados originais continuassem representadas corretamente na estrutura relacional construída.

O diagrama correspondente ao modelo lógico, contendo as relações, chaves primárias e chaves estrangeiras definidas, é apresentado a seguir:

Modelo Lógico - Imagem



(c) Modelo Físico

O modelo físico foi desenvolvido a partir do modelo lógico previamente elaborado, utilizando o Sistema Gerenciador de Banco de Dados MySQL para implementação das estruturas relacionais e armazenamento dos dados.

Inicialmente, foi realizada uma etapa de preparação do conjunto de dados utilizado. O dataset original encontrava-se em formato CSV contendo informações relacionadas a músicas, artistas, álbuns e gêneros musicais. Antes da inserção no banco, foi necessário realizar um processo de limpeza e normalização dos dados visando reduzir inconsistências e adequar o conjunto às estruturas definidas no projeto do banco.

Durante a etapa de pré-processamento foram executadas operações de limpeza utilizando scripts em Python, incluindo:

- Remoção de colunas desnecessárias presentes no dataset original;
- Remoção de registros contendo valores nulos;
- Remoção de registros duplicados;
- Separação de atributos compostos, permitindo a normalização dos dados;
- Geração de arquivos CSV independentes para cada entidade do banco.

Após o processo de limpeza, o conjunto de dados apresentou redução no número de registros devido à remoção de duplicatas e inconsistências, permitindo maior integridade na importação.

Os dados foram então separados em arquivos distintos correspondentes às entidades definidas no modelo lógico:

GENERO | ARTISTA | ALBUM | MUSICA | PARTICIPACAO

Com os arquivos preparados, foi realizada a implementação física do banco utilizando comandos SQL para criação das tabelas, definição das chaves primárias e estabelecimento das chaves estrangeiras responsáveis por manter a integridade referencial entre as entidades.

A população do banco foi realizada através da importação dos arquivos CSV gerados durante a etapa de processamento. Para evitar violações de integridade referencial, as tabelas foram populadas obedecendo à ordem de dependência entre as entidades.

A ordem utilizada para inserção dos dados foi:

1. GENERO
2. ALBUM
3. ARTISTA
4. MUSICA
5. PARTICIPACAO

Após a conclusão da importação, foram executadas consultas de validação visando confirmar a correta inserção dos registros e o funcionamento adequado das estruturas criadas.

As consultas executadas incluem contagem total de registros e visualização dos primeiros elementos armazenados em cada tabela, permitindo verificar a consistência dos dados populados.

Tratamento do CSV

```
Linhas originais: 114000
Após remover nulos: 113999
Após remover duplicatas: 89740

  track_id      artists  ... time_signature track_genre
0  5Su0ikwiRyPMVoIQDJUgSV    Gen Hoshino  ...         4      acoustic
1  4qPNDBW1i3p13qLct0Ki3A    Ben Woodward  ...         4      acoustic
2  1iJBSr7s7jYXzM8EGcbK5b  Ingrid Michaelson;ZAYN  ...         4      acoustic
3  6Lfxq3CG4xtTiEg7opyCyx    Kina Grannis  ...         3      acoustic
4  5vjLSffimiIP26QG5WcN2K    Chord Overstreet  ...         4      acoustic

[5 rows x 20 columns]

Quantidade generos:
113

  id_genero  nome
0          1  acoustic
1          2  afrobeat
2          3  alt-rock
3          4  alternative
4          5  ambient
5          6  anime
6          7  black-metal
7          8  bluegrass
8          9  blues
9         10  brazil

Quantidade albuns:
46589

  id_album  nome
0          1  Comedy
1          2  Ghost (Acoustic)
2          3  To Begin Again
3          4  Crazy Rich Asians (Original Motion Picture Sou...
4          5  Hold On

Quantidade artistas:
29858

  id_artista  nome
0           1  Gen Hoshino
1           2  Ben Woodward
2           3  Ingrid Michaelson
3           4  ZAYN
4           5  Kina Grannis

Quantidade musicas:
89740

  id_track      nome  popularidade  tempo_ms  FK_GENERO_id_genero  FK_ALBUM_id_album
0  5Su0ikwiRyPMVoIQDJUgSV    Comedy           73    230666             1             1
1  4qPNDBW1i3p13qLct0Ki3A  Ghost - Acoustic           55    149610             1             2
2  1iJBSr7s7jYXzM8EGcbK5b  To Begin Again           57    210826             1             3
3  6Lfxq3CG4xtTiEg7opyCyx  Can't Help Falling In Love           71    201933             1             4
4  5vjLSffimiIP26QG5WcN2K    Hold On            82    198853             1             5

Quantidade participacoes:
123424

  FK_MUSICA_id_track  FK_ARTISTA_id_artista  tipo_participacao
0  5Su0ikwiRyPMVoIQDJUgSV              1      principal
1  4qPNDBW1i3p13qLct0Ki3A              2      principal
2  1iJBSr7s7jYXzM8EGcbK5b              3      principal
3  1iJBSr7s7jYXzM8EGcbK5b              4          feat
4  6Lfxq3CG4xtTiEg7opyCyx              5      principal

CSVs exportados com sucesso.
```

Modelo Físico - BrModelo

```
/* spotify_bd_physical_model: */

CREATE TABLE GENERO (
    id_genero INT PRIMARY KEY,
    nome VARCHAR(100)
);

CREATE TABLE ARTISTA (
    id_artista INT PRIMARY KEY,
    nome VARCHAR(500)
);

CREATE TABLE MUSICA (
    popularidade INT,
    id_track VARCHAR(50) PRIMARY KEY,
    nome VARCHAR(1000),
    tempo_ms INT,
    FK_GENERO_id_genero INT,
    FK_ALBUM_id_album INT
);

CREATE TABLE ALBUM (
    id_album INT PRIMARY KEY,
    nome VARCHAR(200)
);

CREATE TABLE PARTICIPACAO (
    FK_MUSICA_id_track VARCHAR(50),
    FK_ARTISTA_id_artista INT,
    tipo_participacao VARCHAR(50),
    PRIMARY KEY (FK_MUSICA_id_track, FK_ARTISTA_id_artista)
);

ALTER TABLE MUSICA ADD CONSTRAINT FK_MUSICA_2
    FOREIGN KEY (FK_GENERO_id_genero)
    REFERENCES GENERO (id_genero)
    ON DELETE RESTRICT;

ALTER TABLE MUSICA ADD CONSTRAINT FK_MUSICA_3
    FOREIGN KEY (FK_ALBUM_id_album)
    REFERENCES ALBUM (id_album)
    ON DELETE RESTRICT;

ALTER TABLE PARTICIPACAO ADD CONSTRAINT FK_PARTICIPACAO_1
    FOREIGN KEY (FK_MUSICA_id_track)
    REFERENCES MUSICA (id_track)
    ON DELETE RESTRICT;

ALTER TABLE PARTICIPACAO ADD CONSTRAINT FK_PARTICIPACAO_2
    FOREIGN KEY (FK_ARTISTA_id_artista)
    REFERENCES ARTISTA (id_artista)
    ON DELETE RESTRICT;
```

Estrutura Física das Tabelas

GENERO

- id_genero (PK)
- nome

ARTISTA

- id_artista (PK)
- nome

ALBUM

- id_album (PK)
- nome

MUSICA

- id_track (PK)
- nome
- popularidade
- tempo_ms
- FK_GENERO_id_genero (FK)
- FK_ALBUM_id_album (FK)

PARTICIPACAO

- FK_MUSICA_id_track (PK + FK)
- FK_ARTISTA_id_artista (PK + FK)
- tipo_participacao

Evidências do Banco de dados

Criação, acesso e tabelas

```
mysql> SHOW DATABASES;
+-----+
| Database |
+-----+
| catalogo_filmes |
| information_schema |
| mysql |
| performance_schema |
| spotify_db |
| sys |
+-----+
6 rows in set (0.00 sec)

mysql> USE spotify_db;
Database changed
mysql> SHOW TABLES;
+-----+
| Tables_in_spotify_db |
+-----+
| album |
| artista |
| genero |
| musica |
| participacao |
+-----+
5 rows in set (0.00 sec)
```

Detalhes das tabelas

```
mysql> DESCRIBE genero;
+-----+-----+-----+-----+-----+-----+
| Field | Type | Null | Key | Default | Extra |
+-----+-----+-----+-----+-----+-----+
| id_genero | int | NO | PRI | NULL | |
| nome | varchar(100) | YES | | NULL | |
+-----+-----+-----+-----+-----+-----+
```

```
mysql> DESCRIBE artista;
+-----+-----+-----+-----+-----+-----+
| Field | Type | Null | Key | Default | Extra |
+-----+-----+-----+-----+-----+-----+
| id_artista | int | NO | PRI | NULL | |
| nome | varchar(500) | YES | | NULL | |
+-----+-----+-----+-----+-----+-----+
2 rows in set (0.00 sec)
```

```
mysql> DESCRIBE album;
+-----+-----+-----+-----+-----+-----+
| Field | Type | Null | Key | Default | Extra |
+-----+-----+-----+-----+-----+-----+
| id_album | int | NO | PRI | NULL | |
| nome | varchar(500) | YES | | NULL | |
+-----+-----+-----+-----+-----+-----+
2 rows in set (0.00 sec)
```

```
mysql> DESCRIBE participacao;
```

Field	Type	Null	Key	Default	Extra
FK_MUSICA_id_track	varchar(50)	NO	PRI	NULL	
FK_ARTISTA_id_artista	int	NO	PRI	NULL	
tipo_participacao	varchar(50)	YES		NULL	

3 rows in set (0.00 sec)

```
mysql> DESCRIBE musica;
```

Field	Type	Null	Key	Default	Extra
popularidade	int	YES		NULL	
id_track	varchar(50)	NO	PRI	NULL	
nome	varchar(1000)	YES		NULL	
tempo_ms	int	YES		NULL	
FK_GENERO_id_genero	int	YES	MUL	NULL	
FK_ALBUM_id_album	int	YES	MUL	NULL	

6 rows in set (0.00 sec)

Evidência de população

```
mysql> SELECT COUNT(*) FROM genero;
```

COUNT(*)
113

1 row in set (0.00 sec)

```
mysql> SELECT * FROM genero LIMIT 10;
```

id_genero	nome
1	acoustic
2	afrobeat
3	alt-rock
4	alternative
5	ambient
6	anime
7	black-metal
8	bluegrass
9	blues
10	brazil

10 rows in set (0.00 sec)

```
mysql> SELECT COUNT(*) FROM album;
```

COUNT(*)
46589

1 row in set (0.00 sec)

```
mysql> SELECT * FROM album LIMIT 10;
```

id_album	nome
1	Comedy
2	Ghost (Acoustic)
3	To Begin Again
4	Crazy Rich Asians (Original Motion Picture Soundtrack)
5	Hold On
6	Days I Will Remember
7	Is There Anybody Out There?
8	We Sing. We Dance. We Steal Things.
9	Hunger
10	Episode

10 rows in set (0.00 sec)

```
mysql> SELECT COUNT(*) FROM artista;
+-----+
| COUNT(*) |
+-----+
|      29858 |
+-----+
1 row in set (0.00 sec)

mysql> SELECT * FROM artista LIMIT 10;
+-----+-----+
| id_artista | nome |
+-----+-----+
|          1 | Gen Hoshino |
|          2 | Ben Woodward |
|          3 | Ingrid Michaelson |
|          4 | ZAYN |
|          5 | Kina Grannis |
|          6 | Chord Overstreet |
|          7 | Tyrone Wells |
|          8 | A Great Big World |
|          9 | Christina Aguilera |
|         10 | Jason Mraz |
+-----+-----+
10 rows in set (0.00 sec)
```

```
mysql> SELECT COUNT(*) FROM musica;
+-----+
| COUNT(*) |
+-----+
|      89740 |
+-----+
1 row in set (0.01 sec)

mysql> SELECT * FROM musica LIMIT 10;
+-----+-----+-----+-----+-----+-----+
| popularidade | id_track | nome | tempo_ms | FK_GENERO_id_genero | FK_ALBUM_id_album |
+-----+-----+-----+-----+-----+-----+
|          44 | 0000vdREvCVMxbQTkS888c | Lolly | 160725 | 40 | 19251 |
|          47 | 000CC8EParg640mTxVnZ0p | It's All Coming Back To Me Now (Glee Cast Version) | 322933 | 18 | 8887 |
|          22 | 000Iz0K615UepwSJ5z2RE5 | Bóixig Leise - Pig & Dan Remix | 515360 | 74 | 20096 |
|          19 | 000qpd0c97IMTBvF8gwcpy | Tíef | 331240 | 74 | 26140 |
|          62 | 000RDCYioLteXcut0jewey | Teeje Week | 190203 | 52 | 24335 |
|          24 | 0017XiMkqbTfF2AU0zlhj6 | Thanksgiving Chicken | 127040 | 19 | 9486 |
|           0 | 001APMD0L3qtx1526T11n1 | Better | 176320 | 16 | 1826 |
|          30 | 001pyq8FLNSL1C8orNLI0b | Poor Man | 214600 | 8 | 3817 |
|          38 | 001YQlnDSduXdSLgBd66gT | EL Tiempo Es Dinero - Remasterizado 2007 | 177266 | 86 | 36802 |
|          17 | 002qpSULhHAw6DGqFxba01 | Love Generation | 410666 | 47 | 22288 |
+-----+-----+-----+-----+-----+-----+
10 rows in set (0.00 sec)
```

```
mysql> SELECT COUNT(*) FROM participacao;
+-----+
| COUNT(*) |
+-----+
|      123424 |
+-----+
1 row in set (0.02 sec)

mysql> SELECT * FROM participacao LIMIT 10;
+-----+-----+-----+
| FK_MUSICA_id_track | FK_ARTISTA_id_artista | tipo_participacao |
+-----+-----+-----+
| 0000vdREvCVMxbQTkS888c | 14057 | principal |
| 000CC8EParg640mTxVnZ0p | 5830 | principal |
| 000Iz0K615UepwSJ5z2RE5 | 8518 | feat |
| 000Iz0K615UepwSJ5z2RE5 | 11602 | principal |
| 000qpd0c97IMTBvF8gwcpy | 11602 | principal |
| 000RDCYioLteXcut0jewey | 16920 | principal |
| 0017XiMkqbTfF2AU0zlhj6 | 6246 | principal |
| 001APMD0L3qtx1526T11n1 | 4748 | principal |
| 001APMD0L3qtx1526T11n1 | 4769 | feat |
| 001pyq8FLNSL1C8orNLI0b | 2260 | principal |
+-----+-----+-----+
10 rows in set (0.00 sec)
```

=====